

Curso Superior de Desenvolvimento de Software Multiplataforma

Fernando Chibli, 3011392323017

Iago Rossan, 3011392413038

Isabel Maito, 3011392413045

Lucas Consani, 3011392413046

Atividade Rede Neural Regressão (MLP vs. Linear Regression)

Aprendizado em Máquina

Orientador

Prof^a Waldemar Bonventi Junior

1. Base de Dados

Base de dados: Algerian Forest Fires Dataset

Site de origem:

<https://archive.ics.uci.edu/dataset/547/algerian+forest+fires+dataset>

2. Parâmetros de Entrada

```
# -*- coding: utf-8 -*-  
"""Regressão – Algerian Forest Fires (UCI ID 547)  
Target (y): FWI – Fire Weather Index (variável contínua, range 0-31.1)  
"""
```

```
#%% Carregar e limpar o CSV  
# skiprows=1 pula o título "Bejaia Region Dataset"; a linha 2 é o cabeçalho real.  
# Linhas separadoras da 2ª região viram NaN após pd.to_numeric e são removidas.  
df = pd.read_csv('Algerian_forest_fires_dataset_UPDATE.csv', skiprows=1)  
df = df[[c for c in df.columns if 'class' not in c.strip().lower()]] # remove coluna Classes  
df = df.apply(pd.to_numeric, errors='coerce').dropna().reset_index(drop=True)  
print(f"Base carregada: {len(df)} amostras, {df.shape[1]} colunas")  
print(df.describe())  
input('\nAperte ENTER para definir X e y...')
```

3. Base Carregada

```
Base carregada: 243 amostras, 13 colunas
count 243.000000 243.000000 243.0 243.000000 243.000000 243.000000 ... 243.000000 243.000000 243.000000 243.000000 243.000000 243.000000
mean 15.761317 7.502058 2012.0 32.152263 62.041152 15.493827 ... 77.842387 14.680658 49.430864 4.742387 16.690535 7.035391
std 8.842552 1.114793 0.0 3.628039 14.828160 2.811385 ... 14.349641 12.393040 47.665606 4.154234 14.228421 7.440568
min 1.000000 6.000000 2012.0 22.000000 21.000000 6.000000 ... 28.600000 0.700000 6.900000 0.000000 1.100000 0.000000
25% 8.000000 7.000000 2012.0 30.000000 52.500000 14.000000 ... 71.850000 5.800000 12.350000 1.400000 6.000000 0.700000
50% 16.000000 8.000000 2012.0 32.000000 63.000000 15.000000 ... 83.300000 11.300000 33.100000 3.500000 12.400000 4.200000
75% 23.000000 8.000000 2012.0 35.000000 73.500000 17.000000 ... 88.300000 20.800000 69.100000 7.250000 22.650000 11.450000
max 31.000000 9.000000 2012.0 42.000000 90.000000 29.000000 ... 96.000000 65.900000 220.400000 19.000000 68.000000 31.100000

[8 rows x 13 columns]
```

4. Definição de X e Y


```
X: ['Temperature', 'RH', 'Ws', 'Rain ', 'FFMC', 'DMC', 'DC', 'ISI', 'BUI']
y: FWI (range: 0.0 → 31.1 )

Range das variáveis (min → max):
Temperature : 22.0 → 42.0
RH           : 21.0 → 90.0
Ws           : 6.0 → 29.0
Rain         : 0.0 → 16.8
FFMC         : 28.6 → 96.0
DMC          : 0.7 → 65.9
DC           : 6.9 → 220.4
ISI          : 0.0 → 19.0
BUI          : 1.1 → 68.0
```

Observou-se que as variáveis de entrada (X) possuem "ranges" muito diferentes. Por exemplo, a Temperature varia de 22.0 a 42.0, enquanto o DC varia de 6.9 a 220.4, e a RH vai de 21.0 a 90.0. Devido a essa disparidade, o uso do StandardScaler para normalizar as variáveis (trazendo-as para uma mesma escala) é essencial para o bom funcionamento dos modelos, especialmente da rede neural.

Utilizando o train_test_split, os dados foram separados em 80% para treinamento e 20% para teste, resultando em **194 amostras para treino** e **49 amostras para teste**.


5. Pairplot



Treino: 194 amostras | Teste: 49 amostras

O gráfico `sns.pairplot` gerado permite visualizar o cruzamento de todas as variáveis preditoras (X) com a variável alvo (y). Através dele, é possível notar visualmente que algumas variáveis apresentam uma correlação mais linear e direta com o FWI (como os índices ISI, BUI e DMC), enquanto variáveis como Rain ou Ws apresentam distribuições mais concentradas ou dispersas, indicando relações mais complexas ou menor impacto isolado.

6. MLPRegressor




```
=== MLPRegressor ===  
MAE : 0.2842  
MSE : 0.1528  
RMSE: 0.3909  
  
--- Parâmetros da Rede ---  
Camadas ocultas : (100,)  
Ativação : relu  
Épocas (ciclos) : 1790  
Nº camadas total : 3  
Atributos entrada : 9  
Ativação saída : identity  
Loss final : 0.056657
```

A rede neural foi configurada com 100 neurônios na camada intermediária (oculta) e treinada com sucesso.

- **Desempenho:** A rede obteve um Erro Médio Absoluto (MAE) de 0.2842.
- **Gráfico yTest vs. yPred:** O gráfico de dispersão mostra os pontos previstos extremamente alinhados com a diagonal real, indicando um excelente ajuste do modelo aos dados, com pouquíssimo desvio.
- **Parâmetros Utilizados pela Rede:**
 - Camadas ocultas: (100,)
 - Função de Ativação: relu
 - Épocas (ciclos de iteração): 1790 (suficiente para a convergência, resultando numa Loss final de 0.056657)
 - Atributos de entrada: 9
 - Ativação de saída: identity

7. LinearRegression



```
=== LinearRegression ===
MAE : 0.4240
MSE : 0.3554
RMSE: 0.5962
```

```
--- Equação Multilinear ---
FWI = 7.4201
-0.0682 * (Temperature)
-0.0782 * (RH)
-0.0943 * (Ws)
+0.0314 * (Rain)
-0.7185 * (FFMC)
+0.1328 * (DMC)
-0.3159 * (DC)
+5.2428 * (ISI)
+3.9554 * (BUI)
```

```
=====
RESUMO FINAL
=====
MAE - MLPRegressor      : 0.2842
MAE - LinearRegression: 0.4240

Menor MAE -> MLPRegressor
```

O modelo de Regressão Linear Múltipla também foi treinado para estabelecer uma relação puramente matemática e linear entre as variáveis.

- **Desempenho:** A regressão linear obteve um **MAE** de **0.4240**. O resultado foi bom, mas inferior ao da Rede Neural (que foi capaz de capturar relações não-lineares). O gráfico yTest vs yPred mostra os pontos seguindo a tendência, mas com uma dispersão ligeiramente maior que a MLP.

- **Equação Multilinear Levantada:**

Com base nos coeficientes gerados pelo modelo, a equação da reta é:

$$FWI = 7.4281 - 0.0682(Temperature) - 0.0782(RH) - 0.0943(Ws) + 0.0314(Rain) - 0.7185(FFMC) + 0.1328(DMC) - 0.3159(DC) + 5.2428(ISI) + 3.9554(BUI)$$

8. Por que na classificação usamos matriz de confusão e na regressão não? O que é utilizado no lugar?

A **Matriz de Confusão** é utilizada exclusivamente em problemas de classificação porque seu objetivo é contar "acertos e erros" categóricos. Ela verifica se uma classe prevista pelo modelo (ex: "Fogo" ou "Não Fogo") bate exatamente com a classe real.

Na **Regressão**, a variável alvo (y) é um número contínuo (como o FWI que pode ser 15.2, 18.7, 31.1). Como a chance de o modelo prever exatamente o mesmo número com todas as casas decimais é quase nula, não faz sentido contar "acertos absolutos" e preencher uma matriz.

O que é utilizado no lugar?

No lugar da matriz de confusão, utilizamos métricas que medem a "distância" ou a "magnitude do erro" entre o valor numérico previsto e o valor real. As principais são:

- **MAE (Erro Médio Absoluto):** Mostra, em média, o quanto o modelo errou para mais ou para menos, na mesma unidade do dado original (utilizado neste relatório).
- **MSE (Erro Quadrático Médio) e RMSE (Raiz do Erro Quadrático Médio):** Penalizam erros maiores.
- **R^2 (Score R-quadrado):** Mostra a porcentagem da variância dos dados que o modelo conseguiu explicar.

9. Conclusão

O experimento demonstrou que a **Rede Neural (MLPRegressor)** obteve um desempenho superior ao modelo de Regressão Linear na previsão do Índice de Risco de Incêndio (FWI), apresentando um erro significativamente menor (MAE de 0.2842 contra 0.4240). Isso indica que as variáveis meteorológicas e os índices florestais possuem relações complexas e não-lineares, que a rede neural conseguiu mapear com maior eficiência.

Apesar do erro maior, a Regressão Linear provou seu valor analítico ao isolar e demonstrar matematicamente o peso de cada variável, evidenciando que os índices **ISI e BUI** são os principais impulsionadores do risco de incêndio. Por fim, o trabalho consolidou o entendimento teórico de que, para prever valores contínuos como o FWI, métricas de magnitude de erro (como o MAE e o MSE) são as ferramentas corretas para avaliação, em substituição à matriz de confusão utilizada em classificações.